

线性回归的数学原理

AI药物设计 - 第4次课

李哲 副教授

药学院 412B

lizhe5@mail.sysu.edu.cn

2025/12/12

课程信息

基本信息

-  课程名称: AI药物设计
-  第4次课: 线性回归的数学原理

药学意义

线性回归是药物QSAR分析的基础，帮助我们理解分子结构与活性的关系。同时也是AI的基础。

今天的学习目标



前向传播

理解模型预测的计算过程



损失函数

学会衡量预测误差



反向传播

掌握参数调整的数学原理



梯度下降

学会优化算法的核心思想

第一节：前向传播与损失函数

从预测到误差的数学之旅



回顾：房价预测模型

上节课的模型

房价 = 面积 × 单价 + 基础价格

$$y = w \times x + b$$

具体例子

模型参数:

$$w = 1 \text{ 万} / \text{m}^2, b = 10 \text{ 万}$$

输入:

$$x = 100 \text{ m}^2$$

预测:

$$y = 110 \text{ 万元}$$


关键概念

这就是最简单的**前向传播**过程!

数据从输入流向输出的计算过程

前向传播的定义

数据从输入到输出的计算过程



输入数据

房屋面积、分子特征等



模型参数

权重 w 和偏置 b



预测结果

房价、药物活性等

前向传播的步骤拆解

线性回归的前向传播步骤

1 线性计算

$$z = w \times x + b$$

2 输出结果

$$y = z \quad \# \text{ 线性回归直接输出}$$

具体计算示例

```
# 输入数据
x = 100 # 房屋面积

# 模型参数
w = 1.0 # 单价 (万元/m²)
b = 10 # 基础价格 (万元)

# 前向传播计算
z = w * x + b # 1.0 × 100 + 10
y = z # y = 110 (万元)
```

💡 计算结果：预测房价为 110 万元

损失函数

如何衡量预测的好坏？



为什么需要损失函数？

🤔 问题引入

❓ 预测准确吗？

📏 误差有多大？

📈 如何量化误差？

📐 实际案例

预测价格: 110万元

实际价格: 115万元

误差: 5万元

损失函数量化了预测的"错误程度"

均方误差 (MSE) 最常用的损失函数

$$\text{单个样本的损失: } L = (\hat{y} - y)^2$$

- $\hat{y}$ (y-hat): 预测值
- y : 真实值
- L : 损失值

为什么要平方?



消除正负

误差可正可负
平方后都是正值



放大误差

大误差会被放大
更受关注



数学性质好

便于求导
优化简单

损失函数计算示例

单个样本

预测值: $\hat{y} = 110$ 万元

真实值: $y = 115$ 万元


计算过程

平方误差:

$$L = \text{error}^2 = (-5)^2 = 25$$

注意: 损失值25表示误差的大小, 没有单位

图形理解



多个样本的总损失

现实问题：不止一个数据点

房价预测数据

样本	面积(x)	预测价格($\hat{y}$)	实际价格(y)	误差	平方误差
1	80	104	100	4	16
2	120	152	160	-8	64
3	150	188	185	3	9

总损失计算

$$\text{MSE} = (L_1 + L_2 + L_3) / 3 = (16 + 64 + 9) / 3$$

$$= 29.67$$

MSE的意义

平均每个样本的预测误差平方值

反向传播原理

如何调整参数让模型更准确？



偏导数的直观理解

什么是偏导数？

偏导数 = 参数变化对损失的影响程度

⚠ 热水阀门

转动1度 → 温度升高2°C

影响程度 = +2

❄ 冷水阀门

转动1度 → 温度降低1°C

影响程度 = -1

💡 类比到模型

偏导数告诉我们调整w或b对损失L的影响程度

- 正值：增加参数会增加损失
- 负值：增加参数会减少损失

损失函数的坡度

几何直观

想象损失函数是一个山坡：



当前位置：现在的参数值



目标：到达山谷（最小损失）



坡度：偏导数的值



下山方向：坡度的反方向



数学表示

对于损失函数 $L = (wx + b - y)^2$ ：

- 对 w 的偏导数: $\partial L / \partial w$
- 对 b 的偏导数: $\partial L / \partial b$

线性回归的偏导数推导

对于单个样本，损失函数 $L = (\hat{y} - y)^2 = (wx + b - y)^2$

1 对w的偏导数

$$\partial L / \partial w = 2 \times (wx + b - y) \times x$$

$$= 2 \times (\hat{y} - y) \times x$$

2 对b的偏导数

$$\partial L / \partial b = 2 \times (wx + b - y) \times 1$$

$$= 2 \times (\hat{y} - y)$$

具体例子

- 输入 $x = 100$ ，真实值 $y = 115$
- 当前预测 $\hat{y} = 110$ (误差 = -5)

$$\partial L / \partial w = 2 \times (-5) \times 100 = -1000$$

$$\partial L / \partial b = 2 \times (-5) = -10$$

💡 解释: w的改变对损失的影响是b的100倍 (因为 $x=100$)

第二节：梯度下降与多元回归

优化算法的核心



梯度下降算法



下山的比喻

想象你站在山坡上，目标是到达山谷（最低点）：



1. 确定位置

当前的参数值



2. 找方向

计算梯度（坡度）



3. 走一步

沿反方向前进



重复过程

不断重复直到到达谷底

参数更新规则

梯度下降的数学表达

$$w_{\text{new}} = w_{\text{old}} - \alpha \times \partial L / \partial w$$

$$b_{\text{new}} = b_{\text{old}} - \alpha \times \partial L / \partial b$$

其中 α (alpha) 是学习率

具体例子

初始条件:

- 参数: $w = 1.0, b = 10$
- 梯度: $\partial L / \partial w = -1000, \partial L / \partial b = -10$
- 学习率: $\alpha = 0.0001$

更新计算:

$$w_{\text{new}} = 1.0 - 0.0001 \times (-1000) = 1.1$$

$$b_{\text{new}} = 10 - 0.0001 \times (-10) = 10.001$$

学习率的作用和影响

经验法则: 通常从0.001开始尝试，根据效果调整

拓展到多元线性回归

从一元到多元的数学扩展

多元线性回归模型

从一个特征到多个特征

一元线性回归

$$y = w \times x + b$$

只考虑一个因素（如面积）

多元线性回归

$$y = w_1 \times x_1 + w_2 \times x_2 + w_3 \times x_3 + b$$

同时考虑多个因素

房价预测的多元模型

$$\text{房价} = w_1 \times \text{面积} + w_2 \times \text{卧室数} + w_3 \times \text{楼层} + b$$

例如：

- 面积：100m²
- 卧室数：3个
- 楼层：8层



优势：考虑更多因素，预测更准确

类比：分子性质预测

就像房价取决于多个因素，**药物的生物活性**也取决于多个分子特征：

- • 房屋面积 → 分子量 (MW)
- • 卧室数量 → 氢键供体数 (HBD)
- • 楼层高度 → 脂溶性 (LogP)
- • 地理位置 → 极性表面积 (PSA)

药物活性预测模型

$$\text{活性} = w_1 \times \text{MW} + w_2 \times \text{LogP} + w_3 \times \text{HBD} + w_4 \times \text{PSA} + b$$

完全相同的数学形式！

具体例子：阿司匹林

就像计算房价一样：

- • MW = 180.2 ("面积")
- • LogP = 1.2 ("楼层")
- • HBD = 1 ("卧室数")
- • PSA = 63.6 ("位置评分")

重要启示

线性回归不仅能预测房价，在药学中同样有着广泛应用：

- • 药物活性预测
- • 剂量-效应关系
- • ADMET性质预测
- • 个体化用药剂量

通过代码深入理解多元线性回归的实现过程

上jupyter notebook实操

1. 数据准备

```
import numpy as np

# 特征矩阵 (n_samples × n_features)
X = np.array([
    [180.2, 1.2, 1, 63.6],    # 阿司匹林
    [314.5, 3.1, 2, 86.2],    # 布洛芬
    [151.2, 0.9, 3, 77.8]     # 扑热息痛
])
# 目标值
y = np.array([2.8, 3.5, 2.1])
# 初始化权重
w = np.random.randn(4)
b = 0
```

2. 前向传播

```
def forward(X, w, b):
    """计算预测值"""
    return X @ w + b
```


完整的训练循环

```
epochs = 1000
learning_rate = 0.01

for epoch in range(epochs):
    # 前向传播
    y_pred = forward(X, w, b)
    # 计算损失
    loss = mse_loss(y_pred, y)
    # 反向传播和更新
    w, b = backward_and_update(X, y, y_pred, w, b, learning_rate)
    if epoch % 100 == 0:
        print(f"Epoch {epoch}, Loss: {loss:.4f}")

# 最终模型
print(f"\n训练完成!权重: {w}; 偏置: {b}")

# 新分子预测
new_molecule = np.array([200.3, 2.5, 2, 70.1])
prediction = forward(new_molecule, w, b)
print(f"预测活性: {prediction:.2f}")
```

课程总结

今天学到了什么？

核心概念回顾

第一节内容

前向传播

- 从输入到输出的计算过程
- $y = wx + b$ 的具体计算

损失函数

- 均方误差 $MSE = (\hat{y} - y)^2$
- 量化预测的准确度

反向传播原理

- 偏导数的直观理解
- 参数对损失的影响

第二节内容

梯度下降算法

- 参数更新规则
- 学习率的重要性

多元线性回归

- 从一元到多元的拓展
- 矩阵表示和计算

Python实现

- 完整的训练循环
- 药物分子应用

重要公式总结

1. 线性模型

一元： $y = wx + b$

多元： $y = w_1x_1 + w_2x_2 + \dots + w_nx_n + b$

2. 损失函数

单样本： $L = (\hat{y} - y)^2$

多样本： $MSE = (1/n) \times \sum (\hat{y}_i - y_i)^2$

3. 梯度

对 w 的偏导： $\partial L / \partial w = 2(\hat{y} - y)x$

对 b 的偏导： $\partial L / \partial b = 2(\hat{y} - y)$

4. 参数更新

$w_{\text{new}} = w_{\text{old}} - \alpha \times \partial L / \partial w$

$b_{\text{new}} = b_{\text{old}} - \alpha \times \partial L / \partial b$



这些公式是深度学习的基础，请务必理解和掌握！

药学应用展望

↑ 这些都是线性回归在药学领域的实际应用

下次课预告

第5次课：从线性到非线性的神经网络



学习内容

- ✓ 线性模型的局限性
- ✓ 激活函数的作用
- ✓ 多层感知机原理
- ✓ 非线性问题求解
- ✓ 神经网络的构建



关键概念

- 📈 ReLU、Sigmoid激活函数
- 🔗 隐藏层的重要性
- 🧪 药物分子非线性建模
- 🌀 万能近似定理

谢谢大家！

数学是深度学习的基础

理解原理，才能更好地应用